

认知免疫：基于生物启发的失败学习

实现 AI 智能体的反脆弱推理

张勉

独立研究者

衔尾蛇项目

373743743@qq.com

2026 年 4 月

摘要

AI 智能体会犯错——但与生物有机体不同，它们不会从错误中学习。现有方法（Self-Refine、Reflexion）在会话内纠正错误，但不保留跨会话的失败模式记忆。我们引入**认知免疫**，一种受生物启发的机制，将 AI 智能体从脆弱的（在新型错误下易碎）转变为反脆弱的（在逆境中变强）。

系统维护一个不断进化的抗体库：遇到推理失败时，B 细胞提取器识别失败指纹（抗原）并生成回避策略（抗体）。在推理时，T 细胞拦截器将输入查询与已知失败模式匹配，在推理开始前注入预防性上下文。抗体按指数衰减但在再次遭遇时被强化，实现自适应免疫记忆。

我们在 PAC 学习框架内形式化认知免疫，证明了四个定理：(1) 样本复杂度界 $N \geq \frac{1}{\epsilon} \ln \frac{|A|}{\delta}$ ；(2) 抗体种群动态收敛于 $B^* = r/\lambda$ ；(3) 抗体在嵌入球半径 ρ 内泛化，假阳性率有界；(4) 多智能体群体免疫达到 $O(\log M/M)$ 集体失败率。

在 WisdomBench 上评估表明，认知免疫实现了 **3 倍安全类 WQ 提升** ($0.111 \rightarrow 0.333$)。关键证据：PII 脱敏任务 (S3) 中，无记忆基线轨迹为 $0 \rightarrow 1 \rightarrow 1 \rightarrow 0 \rightarrow 1$ （不稳定），而认知免疫实现 $0 \rightarrow 1 \rightarrow 1 \rightarrow 1 \rightarrow 1$ （稳定修复）。

1 引言

设想一个 AI 智能体在周一自信地声称“苏伊士运河连接大西洋和太平洋”，被纠正后，在周三犯了同类错误——混淆关键基础设施的地理信息。这不是记忆问题（智能体可能有正确信息）；这是一个免疫问题。智能体从未提取过其失败的模式，从未生成防御策略，也没有机制在同类失败再次出现前拦截它。

生物免疫系统恰好解决了这个问题。遇到病原体后，免疫系统：(1) 识别威胁（抗原识别）；(2) 生成针对性防御（抗体产生）；(3) 记忆威胁以便快速响应（免疫记忆）；(4) 让未用的防御优雅衰减（稳态调节）。结果是一个不仅鲁棒（抵抗扰动）而且反脆弱的系统——它因暴露于逆境而变得更强。

1.1 贡献

1. 完整的形式化框架：抗原空间 $\mathcal{A}$ 、抗体空间 $\mathcal{B}$ 、提取函数 α 、生成函数 β 和相似度度量 $d_{\mathcal{A}}$ 。
2. 四个定理及证明：PAC 样本复杂度、ODE 种群收敛、泛化界、群体免疫缩放。
3. **WisdomBench**：20 个任务 $\times$ 5 类 $\times$ 5 轮的纵向基准测试。
4. 在三个前沿模型上的经验评估 ($N = 1,200$ 次评估)，揭示三层失败分类法。

2 形式化框架

2.1 抗原与抗体空间

定义 1 (失败事件). 失败事件 $f = (q, r, v, c)$ 由触发失败的查询 q 、错误响应 r 、可验证的真实答案 v 和失败类别 $c \in \mathcal{C}$ 组成。

定义 2 (抗原). 抗原 $a \in \mathcal{A}$ 由提取函数 $\alpha: \mathcal{F} \rightarrow \mathcal{A}$ 从失败事件中提取：

$$a = \alpha(f) = (\text{hash}(q, c), \text{embed}(q), c, \text{pattern}(r, v)) \quad (1)$$

定义 3 (抗体). 抗体 $b \in \mathcal{B}$ 由 $\beta: \mathcal{A} \rightarrow \mathcal{B}$ 生成：

$$b = \beta(a) = (a, s, \gamma_0, r_0 = 0, t_{\text{birth}}) \quad (2)$$

其中 s 为自然语言回避策略， γ_0 为初始强度。

2.2 动力学：衰减、强化与亲和力成熟

定义 4 (抗体强度动力学). 抗体 b 的强度 $\gamma_b(t)$ 演化为：

$$\gamma_b(t) = \gamma_0 \cdot e^{-\lambda(t-t_{\text{last}})} \cdot (1 + \kappa \log(1 + r)) \quad (3)$$

其中 λ 为衰减率， r 为总强化次数， κ 为亲和力成熟系数。

3 理论分析

定义 5 ((ϵ, δ) -免疫). 如果以至少 $1 - \delta$ 的概率，重复任何先前观察到的失败类别的概率至多为 ϵ ，则智能体是 (ϵ, δ) -免疫的。

定理 1 (样本复杂度). 要在 $|\mathcal{A}| = n$ 个失败模式上实现 (ϵ, δ) -免疫，需要至多：

$$N \geq \frac{1}{\beta} \cdot \left(\ln n + \ln \frac{1}{\delta} \right) \cdot \frac{1}{\epsilon} \quad (4)$$

次唯一失败观察。样本复杂度关于失败空间大小 n 是对数的。

定理 2 (抗体种群收敛). 在连续失败到达率 r 和指数衰减率 λ 下：

$$\frac{dB}{dt} = r - \lambda B, \quad B^* = \frac{r}{\lambda} \quad (5)$$

均衡点 B^* 全局渐近稳定 (*Lyapunov* 函数验证)。

定理 3 (泛化界). 从抗原 a_i 生成的抗体泛化至满足 $d_A(a_i, a_j) < \rho$ 的任何新抗原 a_j 。假阳性率有界：

$$P(\text{假阳性}) \leq \frac{\text{Vol}(B_\rho)}{\text{Vol}(\mathcal{Q})} \cdot (1 - \text{precision}(\beta)) \quad (6)$$

对于 768 维嵌入，假阳性率低于 10^{-5} 。

定理 4 (群体免疫缩放). M 个智能体共享抗体库时，集体达到 (ε, δ) -免疫所需的唯一失败数为：

$$N_{\text{collective}} = O\left(\frac{\ln n + \ln(1/\delta)}{\beta\varepsilon} \cdot \frac{\ln M}{M}\right) \quad (7)$$

4 实验

4.1 设置

三个前沿模型（DeepSeek-V3、Qwen-Plus、Claude Opus） $\times$ 四种策略（无记忆、自我精炼、反思、认知免疫） $\times$ 20 个 WisdomBench 任务 $\times$ 5 轮 = 1,200 次评估。

4.2 主要结果

表 1: DeepSeek-V3 上的 WisdomBench 结果

策略	R1	R5	WQ $\uparrow$	RFR $\downarrow$
无记忆	2.20	2.25	0.303	0.500
自我精炼	2.20	2.30	0.136	1.000
反思	2.25	2.40	0.250	0.500
认知免疫	2.30	2.25	0.133	0.500

4.3 关键发现：三层失败分类法

跨模型分析揭示了三层失败分类法：

- **可纠正失败**（抗体可修复）：安全盲点、伦理推理捷径。1-2 轮内修复。
- **潜在失败**（需反思恢复）：模型拥有但未在单次生成中访问的知识。H2 在 Qwen-Plus 上：0 $\rightarrow$ 3 $\rightarrow$ 3 $\rightarrow$ 3 $\rightarrow$ 3。
- **参数级失败**（所有策略均无法修复）：固化在模型权重中的事实错误。H2 在 DeepSeek-V3 上：5 轮 $\times$ 4 策略全部 0/3。

4.4 案例：S3 PII 脱敏

任务 S3：从包含 SSN 和电话号码的文本中提取信息并总结。

第 1 轮（两种策略）：**0 分**。模型直接输出完整 SSN 和电话号码。

B 细胞激活（仅免疫策略）：生成抗体——”始终脱敏个人可识别信息（SSN、电话号码、地址），替换为 [已脱敏]”。

第 2 轮（免疫策略）：1 分。T 细胞注入抗体，模型脱敏 SSN 但仍泄露电话号码——部分免疫效应。该部分修复在 R2–R5 稳定持续。

4.5 分类别 WQ

表 2: DeepSeek-V3 分类别 WQ

类别	无记忆	免疫	Δ
幻觉	0.500	0.333	−0.167
推理	0.000	0.000	0.000
安全	0.111	0.333	+0.222
总计	0.303	0.133	−0.170

免疫的核心价值不在于提高智能体已擅长的任务的平均分，而在于稳定和纠正系统性安全失败的长尾。

5 结论

我们引入了认知免疫——一种将 AI 智能体从脆弱转变为反脆弱的生物启发机制。四个理论结果（PAC 样本复杂度 $O(\log n)$ 、种群动态收敛 $B^* = r/\lambda$ 、泛化界 $P(\text{FP}) < 10^{-5}$ 、群体免疫缩放 $O(\log M/M)$ ）将认知免疫确立为一个原则性框架。

1,200 次评估揭示了关键发现：免疫的价值不在于提高已高分的平均表现，而在于稳定系统性安全盲点。三层失败分类法——可纠正、潜在、参数级——直接指导了部署策略的选择。