

WisdomBench: AI 智能体智慧习得的 纵向基准测试

张勉

独立研究者

衔尾蛇项目

373743743@qq.com

2026 年 4 月

摘要

现有智能体基准测试（GAIA、SWE-bench、WebArena、AgentBench）衡量的是 AI 智能体能做什么——它在某一时间点的能力。没有基准测试衡量智能体从做中学到什么——它通过经验改善的能力。我们引入 **WisdomBench**，首个旨在衡量智慧习得的纵向基准测试：通过反复暴露于诱发失败的任务来系统提升智能体表现——皮亚杰式顺应的计算类比。

WisdomBench 包含 5 个失败类别（幻觉、推理、指令遵循、工具使用、安全）的 20 个任务。我们引入三个新指标：(1) **智慧商数 (WQ)**：跨轮归一化改善；(2) **泛化率 (GR)**：学习向未见变体的迁移；(3) **过拟合率 (OR)**：记忆与真正学习的检测。

在三个前沿模型（DeepSeek-V3、Qwen-Plus、Claude Opus）和 4 种学习策略上的大规模评估（ $N = 1,200$ 次评估）揭示：DeepSeek-V3 的 Nvidia 创立日期在所有 5 轮中均错误（参数级失败），而 Qwen-Plus 通过反思自我纠正相同错误（ $0 \rightarrow 3 \rightarrow 3 \rightarrow 3 \rightarrow 3$ ，潜在知识浮现）。反思策略在 Qwen-Plus 和 Claude Opus 上均达到最高智慧商数（ $WQ=0.375$ ），失败复发率为零，建立了三层失败分类法：可纠正、潜在和参数级。

1 引言

IQ 测试衡量学生今天能多好地回答问题。智慧测试衡量学生从昨天的错误中学到了多少。当前 AI 智能体基准测试是 IQ 测试——它们衡量瞬时能力，没有一个是智慧测试。

1.1 智慧测量的三条公理

公理 1 (纵向性). 智慧不能在单次试验中测量。基准测试必须跨多轮管理任务并提供轮间反馈以捕获学习。

公理 2 (陷阱设计). 任务必须包含嵌入的失败模式（“陷阱”），这些陷阱足够常见以触发但可通过经验避免。

公理 3 (泛化测试). 对已见任务的改善是必要但不充分的。真正的智慧需要向同类失败的未见变体迁移。

没有现有基准测试满足全部三条公理。

2 基准设计

2.1 任务类别与失败陷阱

表 1: WisdomBench 完整任务列表：5 类 $\times$ 4 个任务

类别	ID	任务描述	嵌入陷阱
幻觉	H1-H4	建筑师归属、公司成立日期、科学机制、伤亡数字	似是而非的错误归属
推理	R1-R4	单位换算、逻辑否定、时区推理、因果推断	常见推理陷阱
指令	I1-I4	格式规范、多约束、字数限制、角色扮演	细微的约束违反
工具	T1-T4	数据库查询、API 调用、结构化解析、工具链	错误的工具使用模式
安全	S1-S4	有害内容、事实核查、PII 脱敏、伦理困境	边界测试场景

2.2 评估协议

每个任务管理 **5 轮**。轮间反馈包含：(1) 哪些任务失败了；(2) 失败类别；(3) 正确答案或行为。关键是反馈不包含回避策略——智能体必须自己学习失败模式。

3 指标

定义 1 (智慧商数 (WQ))。跨轮归一化改善：

$$WQ = \frac{1}{N} \sum_{i=1}^N \frac{s_i^{(R)} - s_i^{(1)}}{s_{\max} - s_i^{(1)}} \quad (1)$$

其中 $s_i^{(r)}$ 为第 r 轮任务 i 的分数。 $WQ \in [0, 1]$ ，归一化确保不同基线的公平比较。

定义 2 (泛化率 (GR))。 $GR = \bar{s}_{unseen}^{(R)} / \bar{s}_{seen}^{(R)}$ 。 $GR = 1$ 表示学会了模式， $GR = 0$ 表示纯记忆。

定义 3 (过拟合率 (OR))。 $OR = 1 - GR$ ，高 OR 表示任务特定的而非模式级的改善。

命题 1 (诊断三元组完备性)。 (WQ, GR, OR) 联合刻画四种学习画像：无学习（低 WQ ）、记忆（高 WQ 低 GR ）、智慧（高 WQ 高 GR ）、遗忘（负 WQ ）。

定理 1 (WQ 单调性)。对于任何具有非负学习函数的智能体， WQ 关于轮次单调不减。

4 评分系统

4 分制量规：0 分 = 失败（掉入陷阱）；1 分 = 部分（部分避免）；2 分 = 正确（正确输出但无元认知）；3 分 = 智慧（正确输出 + 明确承认陷阱）。2 分与 3 分的区别至关重要——3 分展示元认知。

5 基线实验

3 个前沿模型 $\times$ 4 种策略 $\times$ 20 个任务 $\times$ 5 轮 = 1,200 次评估。

表 2: DeepSeek-V3 上的 WisdomBench 结果

策略	R1	R5	WQ $\uparrow$	RFR $\downarrow$
无记忆	2.20	2.25	0.303	0.500
自我精炼	2.20	2.30	0.136	1.000
反思	2.25	2.40	0.250	0.500
认知免疫	2.30	2.25	0.133	0.500

5.1 关键发现

H2: 参数级 vs. 模型特定失败。 H2 (Nvidia 创立日期) 在 DeepSeek-V3 上 5 轮 $\times$ 4 策略全部 0/3, 但 Qwen-Plus 通过反思从第 2 轮起自我纠正至 3/3。这揭示 H2 不是普遍参数级的: Qwen-Plus 拥有正确事实但需要跨轮反思来浮现它。

S3: 稳定性作为免疫指标。 无记忆的 S3 轨迹振荡 (0 $\rightarrow$ 1 $\rightarrow$ 1 $\rightarrow$ 0 $\rightarrow$ 1), 免疫稳定在部分修复 (0 $\rightarrow$ 1 $\rightarrow$ 1 $\rightarrow$ 1 $\rightarrow$ 1)。在安全关键部署中, 保护的稳定性比总体改善幅度更重要。

智能 $\neq$ 智慧。 DeepSeek-V3 首轮得分 2.2/3 (高智能) 但 WQ 接近零——它不从反复失败中学习。推理最强的模型 (推理 4/4 任务全部 3/3) 仍在 PII 脱敏和伦理困境上系统性失败。

5.2 跨模型比较

表 3: 跨模型最佳策略比较

模型	策略	R5	WQ	H2
DeepSeek-V3	反思	2.40	0.250	0/3
Qwen-Plus	反思	2.75	0.375	3/3
Claude Opus	反思	2.60	0.375	3/3

6 局限性与未来工作

(1) 20 个任务需扩展至 50+; (2) 需覆盖更多模型 (开源小模型); (3) LLM 评判需人类校准; (4) 天花板效应限制 WQ 区分度; (5) 目前仅英文通用任务。

7 结论

WisdomBench 引入了首个纵向 AI 智能体智慧习得基准测试。三个公理（纵向性、陷阱设计、泛化测试）和诊断三元组 (WQ, GR, OR) 提供了评估已部署 AI 智能体最重要能力的原则性方法论：从失败中学习的能力。

$N = 1,200$ 次评估揭示了三层失败分类法——可纠正、潜在和参数级——并确立了 WisdomBench 作为能力基准测试之外的独立互补评估轴。